# Deep Learning - Lernen von vielschichtigen neuronalen Netzen

Kjartan Ferstl

DIPLOMARBEIT

eingereicht am

Fachhochschul-Masterstudiengang

Information Engineering und -Management

in Hagenberg

im Juni 2014

# Erklärung

Hiermit erkläre ich an Eides statt, dass ich die vorliegende Arbeit selbstständig und ohne fremde Hilfe verfasst, andere als die angegebenen Quellen und Hilfsmittel nicht benutzt und die aus anderen Quellen entnommenen Stellen als solche gekennzeichnet habe.

Hagenberg, am 11. Juni 2014

Kjartan Ferstl

# Inhaltsverzeichnis

# Vorwort

# Kurzfassung

An dieser Stelle steht eine Zusammenfassung der Arbeit, Umfang max. 1 Seite. Im Unterschied zu anderen Kapiteln ist die Kurzfassung (und das Abstract) üblicherweise nicht in Abschnitte und Unterabschnitte gegliedert. Auch Fußnoten sind hier falsch am Platz.

# Abstract

This should be a 1-page (maximum) summary of your work in English.

# Kapitel 1

# Einleitung

## 1.1 Motivation

Komplexe neuronale Netze können bei einigen Problemstellungen, besonders in der Bild- und Spracherkennung ein sehr mächtiges Mittel zur Problemlösung sein. Das Lernen solcher Netze bringt Schwierigkeiten mit sich die in den vergangenen Jahrzenten schlecht oder gar nicht gelöst werden konnten.

Aufgrund der Weiterentwicklung von PC-Hardware und der Verwendung der Grafik-Recheneinheit (GPU), sind seit den 00er-Jahren bereits bemerkenswerte Ergebnisse möglich. Momentan arbeiten sogar Chiphersteller an preiswerten, dedizierten Chips mit trainierbaren neuronalen Netzen. Qualcomm wird den ersten kommerziellen Chip mit einem integrierten neuronalen Netz noch dieses Jahr (2014) veröffentlichen. Neuronale Netze sind immer nur so gut, wie sie trainiert werden, eines der wesentlichsten Themen im weiteren Fortschritt von neuronalen Netzen sind daher die Algorithmen zum Trainieren.

Aus der eingeleiteten Motivation ergeben sich daher folgende Kernaufgaben für die Seminararbeit:

Google und Facebook werben Deep Learning Spezialisten an

http://deeplearning.net/tag/deep-learning/

http://www.wired.com/2013/12/facebook-yann-lecun/

http://www.wired.com/2014/01/geoffrey-hinton-deep-learning

querbeet information und übersicht http://deeplearning.net/reading-list/

- Einführung in die Problematik von Deep Learning mit kurzem Blick

auf die bisherige Geschichte

- Analyse der Hürden im Deep Learning
- Analyse aktueller Deep Learning-Algorithmen

## 1.2 Ziele und Aufgaben

Folgende zentrale Fragestellungen sollen in der Seminararbeit beantwortet werden:

- Was ist Deep Learning?
- Welche Mustertypen können erkannt werden und welche Anwendungen sind möglich
- Wie sind die gelernten Modelle konkret definiert?
- Welche Verfahren werden verwendet um vielschichtige Modelle zu lernen?
- Was ist aktuell mit Deep Learning in Verbindung mit neuronalen Netzen bei der Mustererkennung in Bildern möglich?

Ziel dieser Arbeit ist es, dem interessierten Leser einen Einstieg in Themen deep learning, mit besonderem Fokus auf neuronale Netze zu vermitteln. Aufbauend auf diesen Erkenntnissen soll gezeigt werden, welche wesentlichen Algorithmen bis heute entwickelt wurden und welche technischen Problemstellungen mit diesen Algorithmen gelöst werden können oder sogar bereits heute damit gelöst werden. Ein wesentlicher Fokus soll dabei auf die Mustererkennung in Bildern gerichtet werden.

## 1.3 Abgrenzung der Arbeit

write

Inhalt...

Achtung, im Rahmen der Verwendung von dinnat und natbib für das Literaturverzeichnis kann nicht `\cite` verwendet werden, sondern es muss `\citep` verwendet werden!

Beispiel: [?], [?], [?], [?], [?], [?].

# Kapitel 2

# Grundlegendes

## 2.1 Definition

eine teil aus dem Bereich der Maschine Learning-Algorithmen zum errechnen vieler Repräsentationen und Features durch die Berechnung nicht-linearer Informationen supervised und unsupervised feature extracaction

Deep Learning kommt aus dem Maschine Learning und befasst sich mit dem maschninellen lernen von vielschichtigen netzten, wie zum Beispiel vielschichtigen neuronalen Netzen oder Deep Belive Netzten.

## 2.2 Entstehung

Der Backpropagation Algorithmus wurde in den 1970ern und 1980ern mehrmals erfunden?! (Werbos, Amari?, Parker, LeCun, Rumelhart, ..)

Backpropagation sah vielversprechend aus, aber in den 1990ern hat er an Bedeutung verlohren da die vielen hidden layer nicht trainiert werden konnten (rechenpower außer bei time-delay und convolutional nets) + hat nicht für netzwerke mit feedback funktioniert

negativ: benötigt gelabelte daten, ungelabelt stehen viel viel viel mehr zur verfügung negativ: zeit für lernen skaliert schlecht negativ: langsam bei netzwerken mit mehreren hidden layern negativ: bleibt oft in lokalen minima hängen, besonders bei vielschichtigen netzten!

frage ob deep-nets wirklich besser als wenigschichtige Netzte sind

supervised gegen unsupervised: ist unsupervised lerning nur ein behelf weil zu wenig gelabelte daten vorhanden sind oder ist eigentlich jedes lernen unsupervised und es scheitert nur an der Rechenleistung?

wie viel wissen sollten wir vorab in die daten stecken (kantenerkennung etc.),

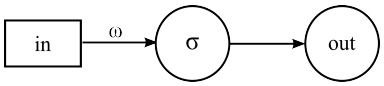


**Abbildung 2.1:** Neuron

ist das netzt mit entsprechender Rechenpower nicht immer besser?

backpropagation-limitierungen mit notwendigkeit für gelabelte daten aufheben: mit unsupervised-learning beheben, gewichte anpassen wie in backpropagation gut, aber versuchen das eingangsbild aus den parametern wiederherzustellen, damit lernt das netz automatisch in unterster schicht wie bilder aussehen bevor es bilder identifiziert

backpropagation invented several times in the 1970 and 1980

heute besonders durch die vermehrte Speicherung von unkategorisierten Daten durch Unternehmen wie Google, Facebook und co. vermehrt unsupervised algorithmen und massiv viel rechenpower vorab rechenpower und datenmänge gewinnt gegen coolen algorithmus

## 2.3 Hürden

rotation, mutation der Natur

beschreibt dass es früher probleme gab, linzer in beteiligung: http://www.kurzweilai.net/how-bio-inspired-deep-learning-keeps-winning-competitions

## 2.4 Neuronale netze

Neuronale Netze sind Strukturen aus der Technik, die dem Nervensystem von Lebewesen ähneln. Es sind Modelle, die Eingangsdaten über Neuronen gewichtet kombinieren und daraus einen Ausgang errechnen. Neuronale Netze sind in der Technik zur Vereinfachung meist in mehreren Schichten aufgebaut.

Abbildung 2.1 zeigt ein einfaches Neuron mit einem Eingang. Ein Eingang wird mit dem Gewicht multipliziert um dann anhand der Übertragungsfunktion den Ausgang zu berechnen. Als Übertragungsfunktion dient meist die Sigmoid-Funktion, welche sich einfach differenzieren lässt und sich daher besonders gut eignet. Der Ausgang *out* dieses Neurons ergibt sich somit aus der dem Eingang *in* multipliziert mit dem Gewicht $\omega$ in der Sigmoid-Funktion

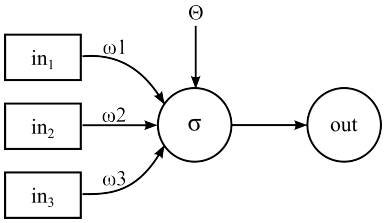


**Abbildung 2.2:** Neuron mit mehreren Eingängen

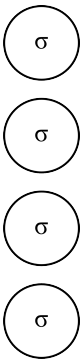


**Abbildung 2.3:** Layer von Neuronen

$\sigma$.

$$out = \sigma(\omega * in)$$

Ein Neuron hat in der Regel, wie in Abbildung 2.2 zu sehen, mehrere Eingänge. Außerdem wird noch ein Bias-Wert $\theta$ für die Sigmoid-Funktion hinzugefügt. Der Ausgang dieses Neurons kann somit wie folgt berechnet werden:

$$out = \sigma(\omega_1 * in_1 + \omega_2 * in_2 + \omega_3 * in_3 + \theta)$$

Um aus den einzelnen Neuronen ein Netzwerk zu machen, werden, wie in Abbildung 2.3 Layer gebildet. Ein Layer ist eine Menge an Neuronen, die untereinander nicht direkt verknüpft sind. Layer werden sequenziell hintereinander gehängt, wobei jedes Neuron eines Layers als Eingang für jedes Neuron des jeweils nächsten Layers dient. Ein solches Netzwerk ist auch in Abbildung 2.4 zu sehen. Dieses Netzwerk hat einen Layer für die Eingabedaten, einen für die Ausgabedaten und zwei innere Layer. Die inneren Layer werden als von außen Unsichtbar betrachtet und daher auch als Hidden-Layer bezeichnet.

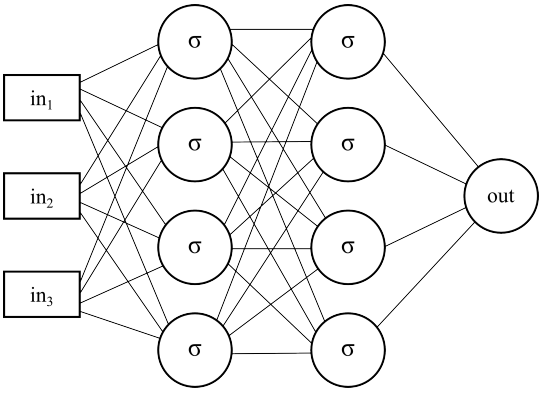


**Abbildung 2.4:** Ein Neuron

# Kapitel 3

# Algorithmen

Fokus: viele Daten, parallele Verarbeitung, viel Rechenpower

## 3.1 Backpropagation

Backpropagation ist ein überwachter Algorithmus zum Trainieren von neuronalen Netzwerken. Bei diesem Algorithmus wird das Netz zunächst mit zufälligen Gewichten belegt.

training algorithmus für neuronale netzwerke

(sigmoid training function als übertragungsfunktion zwischen neuronenverwendet, e function, einfach zu differenzieren) -> output = sigmoid(gewicht*input+theta) theta .. bias

viele inputs in ein neuron

## 3.2 Resctricted Boltzmann Maschines

Uneingeschränkte Neuronale-Netze sind schwierig und aufwendig zu trainieren. Restricted-Boltzmann-Maschines, im weiteren auch als RBMs bezeichnet, sind eingeschränkte neuronale Netzwerke. Wie in Abbildung 3.1 dargestellt, existieren hierbei nur Verbindungen zwischen aneinander liegenden Schichten. Das Modell erlaubt keine Verbindungen von Neuronen zu sich selbst und alle Verbindungen müssen gleichermaßen in beide Richtungen gehen. So lassen sich unter Festlegung der Werte einer Schicht direkt auf die nächste versteckte Schicht weiter gerechnet werden. RBMs arbeiten in der Regel mit bool'schen Werten, lassen sich durch Erweiterung aber auch mit anderen Zahlenräumen verwenden.

RMBs wurden bereits 1986 von Paul Smolensky unter dem Namen Harmo- ref

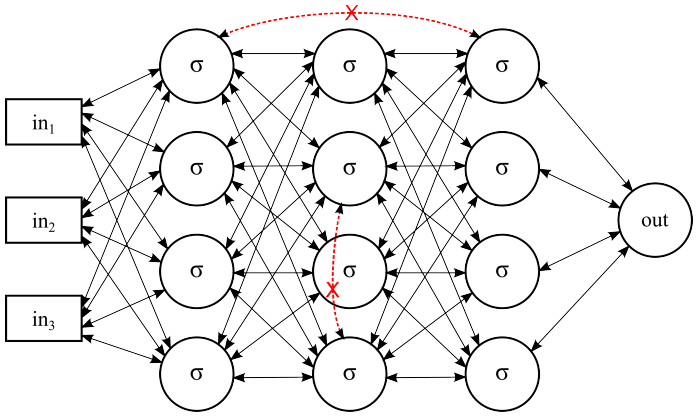


**Abbildung 3.1:** Eine Restricted-Boltzmann-Maschine

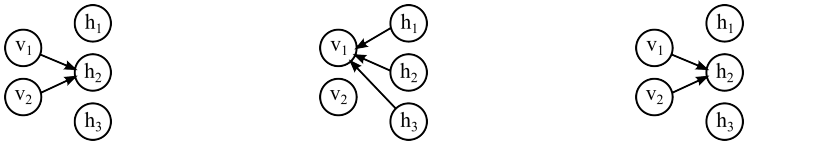


**(a)** Versteckte Schicht berechen

**(b)** Von der versteckten Schicht zurück rechnen

**(c)** Erneut die versteckte Schicht berechnen

**Abbildung 3.2:** Die ersten drei Schritte bei der Berechnung von RBMs.

nium erfunden, fanden jedoch erst 1998, rund 10 Jahre später, durch die Entwicklung von effizienten Lernalgorithmen durch Geoffrey Hinton Anwendung.

Zum trainieren von RMBs existieren verschiedene Algorithmen, die meist auf dem Prinzip beruhen, die Gewichte so anzupassen, das das hin und her Rechen zwischen zwei Schichten wieder die Ausgangsdaten ergibt. Im folgenden wird der Algorithmus von Geoffrey Hinton , der zugleich als der erste effizienten Lernalgorithmus für RMBs gesehen wird, erklärt. reference

### 3.2.1 Grundgedanke

Sind die Werte einer Schicht fixiert, so kann einfach auf die nächste versteckte Schicht weiter gerechnet. Zu beginn werden wird ein Trainingsdatenset an die Eingänge angelegt und die folgenden Operationen wiederholt ausgeführt:

1. Wahrscheinlichkeit für die versteckten Neuronen berechnen

$$p(h_j = 1) = \frac{1}{1 + e^{-(b_j + \sum_i (v_i * w_{ij}))}}$$

2. Werte für die versteckte Schicht aus dem Mittelwert der Wahrscheinlichkeiten berechnen

3. Gradientenmatrix über das dyadische Produkt errechnen

$$< v_i h_j >= v * y^T$$

4. Ausgehend von den errechneten versteckten Neuronen, zurück auf die sichtbare Schicht rechnen

Wiederholt man die in der Liste angeführten Schritte sehr oft, so pendeln sich für die Neuronen Werte ein, die im wesentlichen vom Modell und den den Wahrscheinlichkeiten abhängen, jedoch sehr wenig mit den Eingangsdaten zu tun haben. Anhand der Gradientenmatrix des letzten Durchlaufes lässt sich jedoch eine Distanz zum gewünschten Modell herausfinden und so können die Gewichte wie folgt angepasst werden:

$$\Delta\omega_{ij} = \varepsilon(< v_i h_j >^0 - < v_i h_j >^\infty)$$

Diese Art der Berechnung lieferte sehr gute Modelle. Durch die vielen Iterationen benötigt der Algorithmus sehr viel Rechenzeit und ist daher nicht praxistauglich. Zudem ist es schwierig festzustellen, wie viele Iterationen bis zum Einpendeln notwendig sind.

### 3.2.2 Abkürzung

Der oben genannte Algorithmus lässt sich in seiner Komplexität erheblich reduzieren, in dem die versteckte Schicht lediglich zwei mal berechnet wird. Geoffrey Hinton hat mit der Vereinfachung gezeigt, dass es möglich ist, bereits mit dem Vergleich der ersten und zweiten Gradientenmatrix möglich ist gute Ergebnisse zu erzielen. Diese Methode wird *Contrastive Divergence* genannt.

Die Regel zur Anpassung der Gewichte lautet dann:

$$\Delta\omega_{ij} = \varepsilon(< v_i h_j >^0 - < v_i h_j >^1)$$

### 3.2.3

Das Modell wird mit zufälligen Gewichten initialisiert und Eingangsdaten beaufschlagt. Die erste und sichtbare Schicht mit den Eingangsdaten wird nun als fix angesehen und davon ausgehend mit den Gewichten auf die versteckte Schicht weiter gerechnet. aus diesen Daten wird die erste versteckte Schicht errechnet. Aus der versteckten Schritt wird und daraus wiederrum zurück auf die sichtbare Schicht

Im folgenden wird zur Vereinfachung von einem Boolschen Modell ausgegangen, das heißt, dass ein Neuron lediglich zwei Zustände annehmen kann. Mit entsprechenden Erweiterungen lassen sich später auch andere Werte verarbeiten.

wert festschreiben 1: hidden ausrechnen = inputs*gewichte durch sigmeud, average <vihi> ausrechen 2: inputs aus hidden ausrechnen = hidden*gewichte (sigmoid), average 3: hin und her in sehr langer zeit <vihj> ausrechnen gewichte ändern: delta gewicht = epsilon * (vihj0 - vjhj8)

verbesserung: up down up vihi1 berechnen gewichte ändern: delta gewicht = epsilon * (vihj0 - vihj1) theoretisch blödsinn da mit falschem wert gerechnet wird, funktioniert praktisch aber sehr gut und schnell!

funktioniert weil: das modell wandert weg von den eingangsdaten zu daten die dem modell besser gefallen. nach wenigen Schritten kann bereits erkannt werden wo hin das modell wandert, es kann daher angenommen werden wo hin das modell wandern will und gegengesteuert, so dass es nicht davon wandert

Die Einschränkung vereinfacht das berechnen einer versteckten Schicht und damit das Training des Netzes. Es kann immer eine Schicht als fix angesehen und so zur jeweils zur nächsten weiter gerechnet werden. Initialisiert man das Modell mit Eingangsdaten und zufälligen Gewichten, rechnet immer wieder wiederholt eine Schicht hinein und wieder heraus, während sich die Gewichte nicht ändern, so würde sich das Modell nach sehr langer Zeit auf bestimmte Werte einpendeln bzw. zwischen Werten pendeln. Diese Werte passen gut zu dem Netz, sagen jedoch nicht viel über die Eingangsdaten.

Um das Modell auf die Eingangsdaten zu trainieren, werden diese zunächst als Eingang angelegt und die Gewichte wiederum mit zufälligen Werten initialisiert. Nun wird die zweite und daraus wieder die erste Schicht berechnet. Die Auswirkung auf dein Eingang , und errechnet sich eine wird zu beginn mit zufälligen Gewichten initialisiert, Für das Modell wir eine Energiefunktion aufgestellt, die die Auswirkung Durch die Einschränkung des Netzes kann zur Berechnung der Werte für jeder Übergang von einem Layer auf den nächsten separat betrachtet werden. RBMs eignen sich für überwachtes und unüberwachtes Lernen. Beim unüberwachten Lernen, lernt das Netz RMBs eignen sich

type of neural network for unsupervised learning uses only inputs to train data, no supervised result required target: extract meaningful features for your data verfügbarkeit von unlabeled data ausnützen restriction: allow only connections between the visible and the hidden layers

visible layer, hidden layer energy function propability: high energy ergibt low propability 1

## 3.3 Autoencoders

Autoencoders: Neuronales netz, mit backpropagation trainiert, das zumindest in einer Schicht weniger Neuronen als Eingangsparameter besitzt (bottelneck). Es wir so trainiert, dass der Ausgang dem Eingang entspricht. Steckt man vorne ein Bild hinein und das Netzwerk profezeit am Ausgang das gleiche Bild (mit allen Pixeln), so hat es offensichtlich etwas aus dem Bild gelernt und nicht nur alle Pixel durchgetunnelt (da Anzahl der neuronen kleiner als Anzahl der Pixel). Es etsteht ein "Hash"für die Bilder - der wieder zurückgewandelt werden kann. Würde man es schaffen, beliebige Eingangsdaten sicher wiederherzustellen, so könnte man davon sprechen, dass das Netz das dahinter liegende System (die Natur) erlernt hat. Im weiteren könnte man so zum Beispiel von Bildern, Videos oder Audiospuren lediglich die Ergebnisse des Netztes speichern und die Eingangsdaten jederzeit widerherstellen. So ließen sich diverse Daten unter umständen erheblich komprimieren.

Füttert man solche Algorithmen mit Bildern und visualisiert die entstandenen Gewichte, so erkennt man, dass solche Algorithmen in erster Instanz meist Kanten und Farbintensitäten in Bildern finden. In der zweiten Schicht findet man einfache Kombinationen dieser Elemente und ab der dritten Schicht werden meist schon sehr brauchbare Neuronen zur vollständigen Objekterkennung ausgebildet.

Blockdiagramm mit mehreren Stufen (siehe Bilderkennung), zum Beispiel Matchen+Normalisieren, Matchen+Normalisieren, . . .

## 3.4 Convolutional Neural Networks

bild quelle: http://www.image-net.org/challenges/LSVRC/2012/supervision.pdf

inhalt quelle: wiki, http://googlesystem.blogspot.co.at/2013/06/how-googles-image-recognition-works.html

super video, 10 minuten, erkärt das ganze thema: htt-ps://www.youtube.com

bild

erlärung für bilder: ein neuronales netzwerk, bestehend aus lauter kleineren gruppen an neuronen und vielen schichten. die kleinen Gruppen betrachten Ausschnitte des Bildes und überlappen in ihrer Anordnung. Durch den Blick auf den Ausschnitt eines Bildes wird das dahinter liegende Netzwerk in Teile geteilt und somit die Anzahl der Parameter und somit die Größe und benötigte Trainings und Rechenzeit stark verringert. Durch das Überlappen der einzelnen Bereiche wird berücksichtigt, dass ein späteres High-Level Feature nicht genau in einen Bereich trifft. Das Überlappen gibt es auch zwischen

den einzelnen Layern. Convolutional networks können auch Layer enthalten, die mehrere Ausgänge von neuronen kombinieren, so genannte polling layer.

Dieser Typ von Netzwerk ist bereits 1980 , wurde in den folgenden Jahrzehnten optimiert und erlebte einen Aufschwung durch eine Implementierung auf einer GPU . Nach weiteren Optimierungen in den vergangen Jahren wurde der Algorithmus unter anderem für ein Projekt von Google eingesetzt, das nicht zuletzt das so genannte face-neuron ausprägte.

paper Kunihiko fukushima

Dan Ciresan

google paper finden

convolution: operation that expresses the amount of overlap with another function image preprozessing mit gabor filters, erkennt kanten in alle richtungen

## 3.5 betrachtung als restricted bolzman maschine

# Kapitel 4

# Anwendungen

## 4.1 Bilderkennung

### 4.1.1 Google Projekt

google autoencoder, https://www.youtube.com/watch?v=g4ZmJJWR34Q 23:54

36:00 L2 polling, ignoriert dass ein neuron invertiert ausgelößt wird, zählt alles + auch wenn negativ, da die welt/bilder auch immer verdreht und manipuliert daher kommt, sprache muss akzente ignorieren, gesichtserkennung die haarfarbet etc. auf der richtigen ebene an Features ist das daher ein sehr nützlicher faktor

local constrast normalization, hilft auch bilder invariationen zu ignorieren

google hat mit obrigen in den letzten jahren viel in der Bildersuche und youtube erreicht - was genau?, unsupervised learning mit einer unmänge an daten aus youtube videos

44:46+ bild: stages, drei stages mit jeweils in reihe: filtering, l2 polling, lcn (normalization step) - am ende haben einige neuronen muster erkannt, eines feuert bei gesichtern, eines bei katzen

49:02 number of parameters: 1 billion ... 200x200px bilder, 18x18 filters, 8 filters per location, l2 polling and lcn over 5x5 neighborhoods - wie viele neuronen gesamt?

wegen rechenpower nur mit sehr wenig pixel (200x200) gerechnet, unsere augen sehen n x n pixel, noch einiges möglich

the input image that maximises the neuron to fire: 53:00, das neuron war auf der 3. ebene

neuron auf 1. ebene sind edges, 2. ebene kombinationen von edges, 3. ebene muster wie das gesicht

IMAGENET, Datenbank mit gelabelten bildern an der sich viele Benchmarken

erkennt kanten da farben von der beleuchtung abhängen und somit varriieren

lernen mittels back propagation

## 4.2 Spracherkennung

Deep Learning wird auf dem Gebiet immer stärker und hat die Methode des Gaussian Mixture Models (GMM-Methoden) abgelößt

google now, apply siri, microsoft cortana

mit deep-nets große fortschritte

## 4.3 Fazit aus Anwendungen

Daten Daten Daten

Rechenpower Rechenpower Rechenpower

ergibt: Die großen gewinnen immer

Bessere Algorithmen schaffen dann am meisten wenn sie die Hardware besser nutzen können (parallelisierung, datencenter) damit gewinnen wieder die großen

Kagel .. has data for machine learning algorithms, man löst erkennungsprobleme für Firmen, deren ziel nicht immer ganz ein guter ist.

Was in anderen Bereichen passiert und passieren könnte

Dimensionen in der Zukunft, wo könnte es hin gehen

Traffic sign recognition (99,46prozenz, besser als menschen! gewinner http://www.kurzweilai.net/how-bio-inspired-deep-learning-keeps-winning-competitions)

# Kapitel 5

# Zusammenfassung

## 5.1 Ergebnisse

## 5.2 Allgemeines Resümee

## 5.3 Persönliches Resümee